

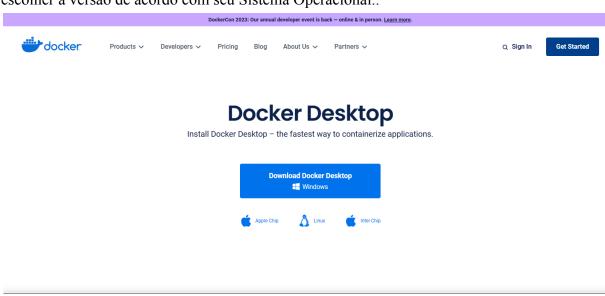
# CURSO SUPERIOR EM ANÁLISE E DESENVOLVIMENTO DE SISTEMAS UNIDADE CURRICULAR DE SISTEMAS DISTRIBUÍDOS

Diórgenes Orlando Paczkowski dos Santos Fagundes e Thales Paulo

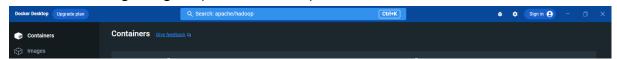
#### Criando e configurando um cluster distribuído com Docker e Apache Hadoop

#### Preparação do ambiente

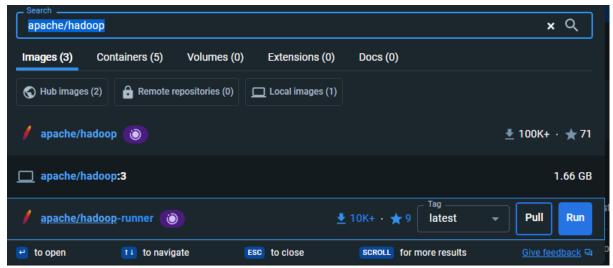
1 - Fazer o download do Docker Desktop em: <u>Download Docker Desktop | Docker</u> e escolher a versão de acordo com seu Sistema Operacional..



2 - Na caixa a seguir digite apache/hadoop.



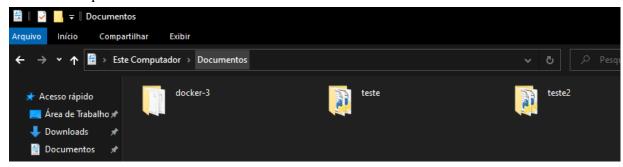
3 - Clique em "Pull" para fazer o download da imagem do hadoop.



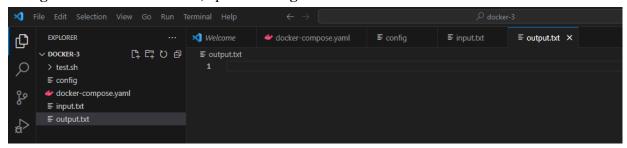


Após a instalação, fazer a configuração dos arquivos necessários.

4 - Crie uma pasta chamada docker-3



5 - Clique com o botão direito na pasta Docker-3 e execute com o Visual Code e crie os seguintes arquivos: **docker-compose.yaml, input.txt, output.txt** e um arquivo chamado **config** sem nenhuma extensão, apenas **config.** 



6 - Dentro de **docker-compose.yaml**, coloque o seguinte código:

```
version: "2"
services:
 namenode:
image: apache/hadoop:3
hostname: namenode
command: ["hdfs", "namenode"]
ports:
- 9870:9870
env_file:
- ./config
environment:
        ENSURE_NAMENODE_DIR: "/tmp/hadoop-root/dfs/name"
datanode1:
image: apache/hadoop:3
command: ["hdfs", "datanode"]
env_file:
- ./config
datanode2:
image: apache/hadoop:3
command: ["hdfs", "datanode"]
env_file:
- ./config
resourcemanager:
    image: apache/hadoop:3
    hostname: resourcemanager
command: ["yarn", "resourcemanager"]
ports:
```



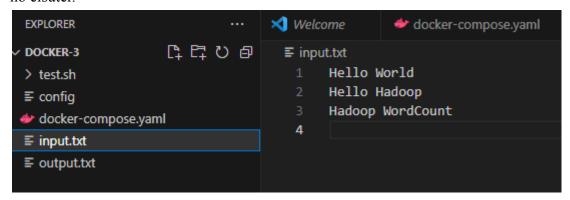
- 8088:8088
env\_file:
- ./config
volumes:
- ./test.sh:/opt/test.sh
nodemanager:
image: apache/hadoop:3
command: ["yarn", "nodemanager"]
env\_file:
- ./config

#### 7 - Dentro de **config**, coloque o seguinte código:

```
CORE-SITE.XML_fs.default.name=hdfs://namenode
CORE-SITE.XML_fs.defaultFS=hdfs://namenode
HDFS-SITE.XML_dfs.namenode.rpc-address=namenode:8020
HDFS-SITE.XML_dfs.replication=1
MAPRED-SITE.XML_mapreduce.framework.name=yarn
MAPRED-SITE.XML_yarn.app.mapreduce.am.env=HADOOP_MAPRED_HOME=$HADOOP_HOME
MAPRED-SITE.XML_mapreduce.map.env=HADOOP_MAPRED_HOME=$HADOOP_HOME
MAPRED-SITE.XML_mapreduce.reduce.env=HADOOP_MAPRED_HOME=$HADOOP_HOME
YARN-SITE.XML_yarn.resourcemanager.hostname=resourcemanager
YARN-SITE.XML_yarn.nodemanager.pmem-check-enabled=false
YARN-SITE.XML_yarn.nodemanager.delete.debug-delay-sec=600
YARN-SITE.XML_yarn.nodemanager.vmem-check-enabled=false
YARN-SITE.XML_yarn.nodemanager.aux-services=mapreduce_shuffle
CAPACITY-SCHEDULER.XML_yarn.scheduler.capacity.maximum-applications=10000
CAPACITY-SCHEDULER.XML_yarn.scheduler.capacity.maximum-am-resource-percent=0.1
CAPACITY-SCHEDULER.XML_yarn.scheduler.capacity.resource-calculator=org.apache.hadoo
p.yarn.util.resource.DefaultResourceCalculator
CAPACITY-SCHEDULER.XML_yarn.scheduler.capacity.root.queues=default
CAPACITY-SCHEDULER.XML_yarn.scheduler.capacity.root.default.capacity=100
CAPACITY-SCHEDULER.XML_yarn.scheduler.capacity.root.default.user-limit-factor=1
CAPACITY-SCHEDULER.XML_yarn.scheduler.capacity.root.default.maximum-capacity=100
CAPACITY-SCHEDULER.XML_yarn.scheduler.capacity.root.default.state=RUNNING
CAPACITY-SCHEDULER.XML_yarn.scheduler.capacity.root.default.acl_submit_applications
CAPACITY-SCHEDULER.XML_yarn.scheduler.capacity.root.default.acl_administer_queue=*
CAPACITY-SCHEDULER.XML_yarn.scheduler.capacity.node-locality-delay=40
CAPACITY-SCHEDULER.XML_yarn.scheduler.capacity.queue-mappings=
{\tt CAPACITY-SCHEDULER.XML\_yarn.scheduler.capacity.queue-mappings-override.enable=false}
```



8 - Crie os arquivos de entrada "input.txt" e coloque algum texto, com aqui no exemplo e saída "output.txt" que ficará vazio. Depois esses arquivos servirão para executar o exemplo no clsuter.



Nesse exemplo é usado o texto:

Hello World Hello Hadoop Hadoop WordCount

Se quiser, é possível alterar esse arquivo para o que desejar.

### Execução do cluster

- 1 Para começar a fazer a configuração dos containers do cluster abra o terminal na pasta do docker-3 em cd <diretório\_da\_pasta\_docker-3> que foi criada inicialmente e execute o seguinte comando
- 2 Iniciando os containers : Executar o comando docker-compose up -d para iniciar o cluster e criar os nós :

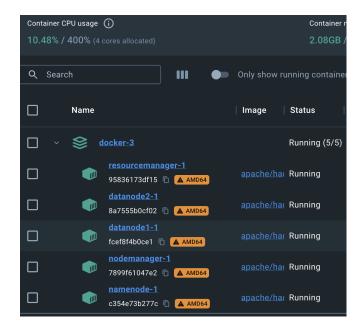
deverá aparecer a mensagem :

```
[+] Running 4/0

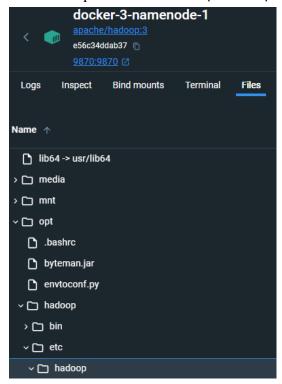
© Container docker3-resourcemanager-1 Running
© Container docker3-nodemanager-1 Running
© Container docker3-namenode-1 Running
© Container docker3-datanode-1 Running
```



3 - Entre no docker e perceba que os containers estão dessa forma:



4 - Precisará alterar o arquivo mapred-site.xml , para isso clique em um deles e clique em "Files" e ache o respectivo diretório /opt/hadoop/etc/hadoop/



5 - Ache dentro desse diretório mapred-site.xml e coloque a configuração para todos os containers.



<configuration>

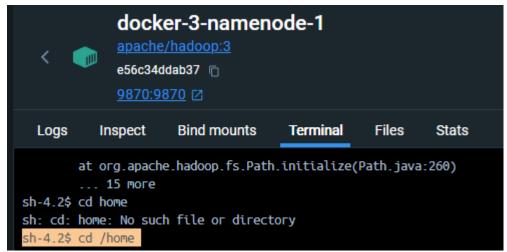
- </configuration>



Atenção faça isso para os demais containers.

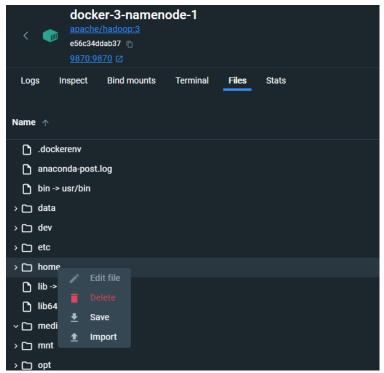
#### Execução do exemplo

1 - No terminal do container **docker-3-namenode** no docker execute cd /home para entrar na pasta home do container, onde será colocada a pasta docker-3

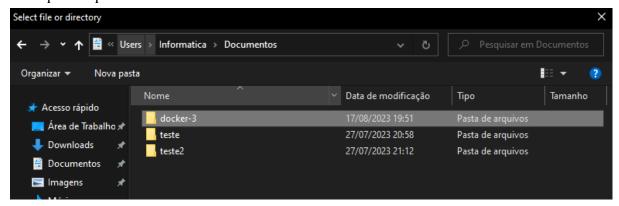




2 - Para executar um programa exemplo que irá ler a quantidade de palavras de um arquivo de texto importe a pasta **docker-3** de um container. No exemplo será usado o **docker-3-namenode-1.** Clique em "Files" dentro do container selecionado, encontre a pasta home clique com o botão direito e em seguida em "Import".

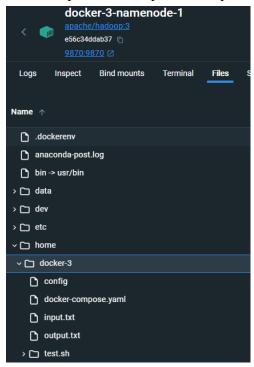


3 - Importe a pasta docker-3





4 - Nessa pasta home aparecerá a pasta docker-3 com seus respectivos arquivos.



5 - Para executar o arquivo input.txt que terá as palavras que serão contadas é necessário colocar os seguintes comandos.

Volte no terminal e coloque os seguintes comandos ls para verificar se a pasta docker-3 está presente no diretório /home, em seguida entre em cd docker-3 e ls para verificar se os arquivos estão presentes

```
sh-4.2$ ls
docker-3
sh-4.2$ cd docker-3
sh-4.2$ ls
config docker-compose.yaml input.txt output.txt test.sh
```

6 - Após verificar os arquivos presentes, digite: hdfs dfs -put input.txt

```
sh-4.2$ hdfs dfs -put input.txt
```

```
Nota: Em caso de erro na execução desse comando sh-4.2$ hdfs dfs -put input.txt put: `.': No such file or directory: `hdfs://namenode/user/hadoop'
```

Execute hdfs dfs -mkdir -p /user/hadoop e volte a executar o comando anterior.

```
sh-4.2$ hdfs dfs -mkdir -p /user/hadoop
sh-4.2$ hdfs dfs -put input.txt
sh-4.2$
```



### 7 - Agora digite:

yarn jar /opt/hadoop/share/hadoop/mapreduce/hadoop-mapreduce-examples-3.3.6.jar wordcount input.txt output.txt

```
sh-4.2$ yarn jar /opt/hadoop/share/hadoop/mapreduce/hadoop-mapreduce-examples-3.3.6.jar wordcount input.txt output.txt
2023-08-17 23:13:37 INFO DefaultNoHARMFailoverProxyProvider:64 - Connecting to ResourceManager at resourcemanager/172.18.0.3:8032
2023-08-17 23:13:37 INFO JobResourceUploader:907 - Disabling Erasure Coding for path: /tmp/hadoop-yarn/staging/hadoop/.staging/job_1692310718604_
2023-08-17 23:13:37 INFO JobSubmitter:209 - Total input files to process : 1
2023-08-17 23:13:37 INFO JobSubmitter:298 - Submitting tokens for job: job_1692310718604_0010
2023-08-17 23:13:37 INFO JobSubmitter:299 - Executing with tokens: []
2023-08-17 23:13:37 INFO ResourceUtlis:476 - Unable to find 'resource-types.xml'.
2023-08-17 23:13:37 INFO Job:1682 - The url to track the job: http://resourcemanager:8088/proxy/application_1692310718604_0010
2023-08-17 23:13:37 INFO Job:1727 - Running job: job_1692310718604_0010
2023-08-17 23:13:42 INFO Job:1727 - Running job: job_1692310718604_0010
2023-08-17 23:13:42 INFO Job:1748 - Job job_1692310718604_0010 running in uber mode : false
```

Esse comando rodará o exemplo em questão e retornará a quantidade de palavras no arquivo output.txt, no entanto para verificar o arquivo output.txt será pelo terminal também.

8 - Após a execução do exemplo, coloque o comando hdfs dfs -ls para verificar os arquivos no diretório em seguida coloque: hdfs dfs -ls output.txt para ver a saída no arquivo output.txt, nota-se que é gerada uma saída em output.txt a output.txt/part-r-00000, para visualizar esse arquivo que contém o resultado da contagem das palavras coloque o comando hdfs dfs -cat output.txt/part-r-00000 e irá aparecer a quantidade de palavras de acordo com o arquivo de texto **input.txt** 

```
Bytes Written=37
sh-4.2$ hdfs dfs
Found 2 items
-rw-r--r-- 1 hadoop supergroup
                                        45 2023-08-17 23:12 input.txt
drwxr-xr-x - hadoop supergroup
                                         0 2023-08-17 23:13 output.txt
sh-4.2$ hdfs dfs -ls output.txt
Found 2 items
-FW-F--F--
            1 hadoop supergroup
                                         0 2023-08-17 23:13 output.txt/_SUCCESS
                                        37 2023-08-17 23:13 output.txt/part-r-00000
-rw-r--r-- 1 hadoop supergroup
sh-4.2$ hdfs dfs -get output.txt/part-r-00000
get: /home/docker-3/part-r-00000._COPYING_ (Permission denied)
sh-4.2$ hdfs dfs -cat output.txt/part-r-00000
Hadoop 2
Hello
WordCount
World
```



9 - Acessando <a href="http://localhost:9870">http://localhost:9870</a> você tem acesso aos datanodes rodando:

## Datanode Information

